Mahdi Bel Haj Said

Ingénieur IA/ML | IA générative · Agents LLM & RAG · Computer Vision

Tunis, Tunisie | Mobilité internationale | mahdi.haj.said@gmail.com | +216 26 957 057

linkedin.com/in/mahdi-bel-haj-said | github.com/Mahdi-Bel-Haj-Said

PROFIL

Ingénieur IA avec plus de 2 ans d'expérience en ingénierie logicielle, dont plus de 18 mois à mettre en production des produits d'IA générative : agents LLM, RAG, fine-tuning LoRA, vision par ordinateur et services FastAPI sur AWS et GPU serverless. Diplômé ingénieur en informatique (équivalent Master), mention Très Bien. Recherche un poste d'Ingénieur IA/ML à temps plein.

FORMATION

Université de Tunis El Manar (UTM) — Tunis, Tunisie

Diplôme National d'Ingénieur en informatique (équivalent Master) — Mention Très Bien 09/2023 – 09/2026

Licence nationale en génie informatique — Mention Très Bien, classé 8e/110 09/2020 – 06/2023

Activités : IEEE Computer Society Chapter (3 ans) ; OPTIMA Junior Entreprise (2 ans)

EXPÉRIENCE PROFESSIONNELLE

Développeur IA (stage) chez Defendr.gg — Tunis, Tunisie (Hybride) 02/2026 – 08/2026

- Conception d'AI Poster Studio, système d'IA générative qui transforme une simple entrée JSON en affiche esport prête à publier en 1 minute environ, pour 0,10 $ par affiche : GPT-4o Vision rédige le prompt image et gpt-image-2 compose le visuel final.
- Fine-tuning LoRA (PyTorch) de Qwen-Image (modèle de diffusion de 20 Md de paramètres) servi depuis un worker GPU serverless RunPod sur mesure, pour générer la bibliothèque d'arrière-plans de chaque affiche.
- Mise en production de bout en bout en SaaS multi-tenant (FastAPI, RQ/Redis, MongoDB, Cloudflare R2, React) : intégré à la plateforme Defendr, coût de développement couvert dès le premier mois, et vendu à un client via une clé API payante.
- Développement de Scout, agent LLM en production (Groq, gpt-oss-20B) qui remplace les formulaires de création de tournois par une conversation et répond aux questions esport et plateforme (FAQ et données en temps réel).

Développeur IA (temps partiel) chez Gamefy Academy — Télétravail 12/2025 – 02/2026

- Développement d'un générateur de highlights esport par IA (Python/FastAPI, Hugging Face Transformers — Whisper, BART — et API Twitch) qui extrait automatiquement les moments clés des VOD et monte les vidéos.
- Construction d'un pipeline ML de transcription audio, détection d'événements et recherche sémantique (embeddings sentence-transformers) sur les transcriptions de matchs, réduisant d'environ 70 % le temps de revue manuelle.

Développeur IA & Web3 chez Defendr.gg — Tunis, Tunisie (Hybride) 08/2025 – 11/2025

- Conception d'un module de vision par ordinateur (prétraitement OpenCV, détection YOLOv8) qui identifie le vainqueur d'un match à partir des captures d'écran des utilisateurs avec 88 % d'exactitude, adapté à chaque jeu et exposé via FastAPI.
- Implémentation de la conversion des soldes du portefeuille de la plateforme en cryptomonnaie via des NFT (smart contracts Solidity, ethers.js), avec gestion des frais de gaz.
- Création d'un module de gamification qui récompense les utilisateurs en pièces de la plateforme selon leur activité sur et en dehors de la plateforme, via des API de jeux externes, convertibles en cryptomonnaie grâce à la conversion par NFT.

Développeur Python (stage) chez Carthage Industries — Tunis, Tunisie 07/2025 – 08/2025

- Développement d'un système automatisé de traitement de documents (Python, OCR, NLP) pour extraire, valider et organiser les documents métier, réduisant de 60 % le temps de saisie manuelle.

Développeur IA chez SCP — Megrine, Tunisie 12/2024 – 05/2025

- Développement d'un outil d'automatisation PDF vers Excel pour les documents métier quotidiens (factures, import/export, etc.) : sélection du type de document, extraction du texte (Tesseract OCR), classification des informations et remplissage automatique d'Excel, avec 99,7 % d'exactitude, 100 documents traités en 20 minutes et une validation humaine optionnelle.
- Déploiement du système 3-tiers complet (backend FastAPI, frontend React, base PostgreSQL) sur AWS (VPC, EC2, S3, IAM).
- Intégration d'un chatbot employés (API OpenAI + RAG ChromaDB) répondant depuis la base de données et les documents de l'entreprise (p. ex. chiffres d'export exacts d'un mois donné), avec garde-fous limitant les réponses au cadre professionnel.

Développeur IA et systèmes embarqués (stage) chez ACTIA — Tunis, Tunisie 06/2024 – 07/2024

- Développement d'un modèle de détection d'anomalies par Random Forest (Python, scikit-learn) qui analyse les logs système et signale les comportements anormaux avec une précision de 71 %.
- Diagnostics matériels et tests de cartes électroniques au service après-vente ; ateliers systèmes embarqués.

Développeur Full Stack (stage) chez HOTIX — Tunis, Tunisie 02/2023 – 06/2023

- Développement d'une application mobile Android en Java de planification de voyages personnalisés, implémentant l'algorithme A* pour générer des itinéraires optimisés selon le budget, le temps disponible et la destination.

COMPÉTENCES

Langages de programmation : Python, JavaScript, TypeScript, C++, Solidity, Java, SQL

IA générative : LLM, agents LLM, RAG, fine-tuning LoRA, modèles de diffusion, LLM multimodaux (GPT-4o Vision), prompt engineering, LangChain, API OpenAI, Groq, évaluation de LLM

Machine Learning : Deep learning, NLP, vision par ordinateur, OCR (Tesseract), détection d'objets (YOLOv8), speech-to-text, PyTorch, Hugging Face Transformers, sentence-transformers, Whisper, scikit-learn, OpenCV, MediaPipe, évaluation de modèles

Backend & Web : FastAPI, API REST, Node.js, Next.js, React, RQ/Redis, Pydantic

Bases de données & stockage : MongoDB, bases vectorielles (ChromaDB), Cloudflare R2, PostgreSQL, MySQL, SQL Server

Cloud & DevOps : Git, Linux, GitHub Actions, Jenkins, RunPod, AWS (EC2, S3, VPC, IAM, Lambda), Docker, SonarQube, Grafana

Langues : Arabe (langue maternelle), Français (C1), Anglais (C1), Espagnol (A2)